


LLMOps • Langfuse • Arquitectura • Modelos

Del **prototipo** al servicio IA

Convertir una demo RAG/MCP en un sistema observable, evaluable y operable.







El bot no responde de forma completa en ciertas situaciones

No se hace un seguimiento del gasto en tokens

Queremos que personal no técnico pueda modificar los prompts sin entrar al código

Es difícil debuggear cuando un usuario ha tenido algún problema



Recuperación



Generación



Recuperación



Utilizar un modelo de embeddings más potente



Utilizar búsqueda híbrida



Mejorar la calidad de los documentos


Generación



Utilizar un modelo de
LLM más potente




“¿Qué está viendo el
modelo?”




Mejorar el prompt
mediante Prompt
Engineering



Modelos Privados



Modelos Open-Source




Motor de Inferencia



Ollama

 vLLM



https://llmfitcheck.com/

✓

LLM Fit Check

will the model run on your box?

What fits

Calculator

Models checked against your hardware in real time

Q Search Hugging Face, or paste a model URL...

YOUR HARDWARE

NV

L40

48 GB VRAM · 32GB RAM

Edit rig

QUANTIZATION

CONTEXT 32K tokens

Q2_K

Q4_K_M

Q5_K_M

Q6_K

Q8_0

FP16

2K

4K

8K

16K

32K

64K

128K

256K

256K+

Trending on Hugging Face

67 of 96 fit

updated 58m ago

☐ Only show what fits

Sort

Trending

list

table

cards

Fits

11.9B

gemma 4 12B coder fable5 composer2.5 v1

yuxinlu1

25.2 GB / 48.0 GB

Best fit: FP16

Won't fit

862B

DeepSeek V4 Pro

deepseek-ai

1606 GB / 48.0 GB

Doesn't fit at any quant

Fits

8.5B

LFM2.5 8B A1B

LiquidAI

16.9 GB / 48.0 GB

Best fit: FP16

Won't fit


158B

DeepSeek V4 Flash


deepseek-ai

295 GB / 48.0 GB

Doesn't fit at any quant



**quantisation
of a
neural network**





RunPod

VAST

